



数学实验

Experiments in Mathematics

实验7 无约束优化

Dept. of Mathematical Sciences

Tsinghua University

Beijing 100084, China

2000-11-11

1

优化模型和算法的重要意义

最优化是工程技术、经济管理、科学研究中
经常遇到的问题

结构设计 资源分配 生产计划 运输方案

解决优化问题的手段

• 经验积累，主观判断

• 作试验，比优劣

• 建立数学模型，求解最优策略

2000-11-11

2

优化问题的数学模型

$$\min_x z = f(x), x \in \Omega \in R^n$$

$x \sim$ 决策变量, $f \sim$ 目标函数, $\Omega \sim$ 可行域

$$\Rightarrow \min_x z = f(x) \quad (1)$$

$$s.t. \quad g_i(x) \leq 0, \quad i = 1, 2, \dots, m \quad (2)$$

- 可行解（只满足(2)）与最优解（满足(1),(2)）
- 无约束优化（只有(1)）与约束优化（(1),(2)）
- 实际问题一般总有约束，何时可用无约束优化处理？

2000-11-11

3



无约束优化的主要内容

1. 优化问题的最优解条件；算法模式
2. 无约束优化的基本方法：梯度法，牛顿法，拟牛顿法
3. 非线性最小二乘法
4. 优化工具箱的使用
5. 实际问题中的无约束优化模型

2000-11-11

4



实例1 产销量安排

某厂生产两个牌号的同一种产品，如何确定产量使利润最大

假设A 产销平衡

牌号	产量	成本	价格
甲	x_1	q_1	p_1
乙	x_2	q_2	p_2

假设B p 随 x (两种牌号)增加而减小，呈线性关系

$$p_1 = b_1 - a_{11}x_1 - a_{12}x_2, \quad b_1, a_{11}, a_{12} > 0, \quad a_{11} > a_{12}$$

$$p_2 = b_2 - a_{21}x_1 - a_{22}x_2, \quad b_2, a_{21}, a_{22} > 0, \quad a_{22} > a_{21}$$

2000-11-11

5



实例1 产销量安排

假设C q 随 x (本牌号)增加而减小，呈负指数关系

$$q_1 = r_1 e^{-\lambda_1 x_1} + c_1, \quad r_1, \lambda_1, c_1 > 0$$

$$q_2 = r_2 e^{-\lambda_2 x_2} + c_2, \quad r_2, \lambda_2, c_2 > 0$$

目标 利润最大

$$\max_{x_1, x_2} z(x_1, x_2) = (p_1 - q_1)x_1 + (p_2 - q_2)x_2$$

2000-11-11

6



实例2 药物的吸收与排除

问题 一室(中心室)模型口服给药方式下的血药浓度 $c(t)$

假设 药物经吸收室进入中心室。药物从吸收室向中心室的转移率与吸收室血药浓度成正比；中心室的排除率与中心室血药浓度成正比。

建模 $\dot{c}_1(t) = -k_1 c_1$


$$V\dot{c}(t) = -kVc + k_1 V_1 c_1$$

$$\dot{c}_1(t) = -k_1 c_1$$

$$\dot{c}(t) = -kc + k_1 c_1 V_1 / V$$

$$c_1(0) = d / V_1, c(0) = 0$$

2000-11-11



($t=0$, 口服剂量 d)

7

模型求解

$$\dot{c}_1(t) = -k_1 c_1$$

$$\dot{c}(t) = -kc + k_1 c_1 V_1 / V$$

$$c_1(0) = d / V_1, c(0) = 0$$

$$c_1(t) = \frac{d}{V_1} e^{-k_1 t}$$

$$c(t) = \frac{d}{V} \frac{k_1}{k_1 - k} (e^{-kt} - e^{-k_1 t})$$

参数估计

用测试分析确定 $c(t)$ 中的参数 k, k_1, V

今测得一组数据 $(t_i, c_i), i=1, \dots, n$

t_i	0.083	0.167	0.25	0.50	0.75	1.0	1.5
c_i							
t_i	2.25	3.0	4.0	6.0	8.0	10.0	12.0
c_i							

2000-11-11

8

参数估计

$$c(t) = \frac{d}{V} \frac{k_1}{k_1 - k} (e^{-kt} - e^{-k_1 t})$$

用最小二乘法求参数 k, k_1, V (已知 d), 使理论值 $c(t_i)$ 与实测值 c_i 的误差平方和最小.

$$R(k, k_1, V) = \sum_{i=1}^n [c(t_i) - c_i]^2 = \sum_{i=1}^n \left[\frac{d}{V} \frac{k_1}{k_1 - k} (e^{-kt_i} - e^{-k_1 t_i}) - c_i \right]^2$$

非线性最小二乘问题, 无约束优化.

约束: $k, k_1, V > 0$?

2000-11-11

9


无约束优化的提法

给定一个函数 $f(x)$, 寻找 x^* 使得 $f(x^*)$ 最小, 即

$$\min_x f(x) \quad \text{其中 } x = (x_1, x_2, \dots, x_n)^T \in \mathbb{R}^n$$

最优解的分类和条件

局部最优解



全局最优解

必要条件

充分条件

$$\nabla f(x^*) = (f_{x_1}, \dots, f_{x_n})^T = 0$$

$$\nabla f(x^*) = 0, \nabla^2 f(x^*) > 0$$

Hessian阵

$$\nabla^2 f = \left[\frac{\partial^2 f}{\partial x_i \partial x_j} \right]_{n \times n}$$

2000-11-11

10



求解无约束优化的基本思路

基本思想 在 \mathbb{R}^n 中某一点，确定一个搜索方向及沿该方向的移动步长，得到使目标函数下降的新的点

迭代
步骤

Step 1 初始化：初始点 x^0 ，终止准则等

Step 2 迭代改进：方向 d^k ，步长 α^k

$$x^{k+1} = x^k + \alpha^k d^k \quad f(x^{k+1}) < f(x^k)$$

Step 3 终止检验：得到近优解或 $k+1 \Rightarrow k$ 转2

选择 d^k, α^k 使 f 下降更快 \Rightarrow 不同算法

2000-11-11

11



无约束优化的基本方法(搜索方向的选择)

1 最速下降法
(梯度法)

暂不考虑搜索步长，
可设 $\alpha^k=1$

将 $f(x^{k+1})$ 在 x^k 点作泰勒展开，只保留一阶项，有

$$f(x^{k+1}) = f(x^k + d^k) = f(x^k) + \nabla f^T(x^k) d^k$$

下降方向

$$\nabla f^T(x^k) d^k < 0$$

最速下降方向

$$d^k = -\nabla f(x^k) \quad (\text{负梯度方向})$$

迭代改进格式

$$x^{k+1} = x^k - \nabla f(x^k)$$

算法特点

初始阶段改进较快，最优解附近改进较慢

2000-11-11

12



2 Newton方法

将 $f(x^{k+1})$ 在 x^k 点作泰勒展开至二阶项, 用 d 替代 d^k

$$f(x^{k+1}) = f(x^k + d) = f(x^k) + \nabla f^T(x^k)d + \frac{1}{2}d^T \nabla^2 f(x^k)d$$

求 d 使 $f(x^{k+1})$ 极小 \Rightarrow 右端对 d 导数为0 $\Rightarrow \nabla f(x^k) + \nabla^2 f(x^k)d = 0$

牛顿方程

$$\nabla^2 f(x^k)d = -\nabla f(x^k)$$

牛顿方向

$$d^k = -(\nabla^2 f(x^k))^{-1} \nabla f(x^k)$$

迭代格式

$$x^{k+1} = x^k - (\nabla^2 f(x^k))^{-1} \nabla f(x^k)$$

特点 局部2阶收敛;需计算Hessian阵,它可能病态或不正定

比较

解 $F(x) = 0$
的牛顿法

$$x^{k+1} = x^k - [F'(x^k)]^{-1} F(x^k)$$

$$F(x) \Leftrightarrow \nabla f(x)$$

2000-11-11

13

3 拟Newton方法

目的

不计算Hessian阵, 克服病态、不正定、计算复杂等缺陷, 同时保持收敛较快的优点

思路

回顾解方程组 $F(x)=0$ 的拟牛顿法

$$x^{k+1} = x^k - [F'(x^k)]^{-1} F(x^k) \quad \Rightarrow \quad x^{k+1} = x^k - (A^k)^{-1} F(x^k)$$

$$\text{使 } A^k \text{ 满足 } A^k(x^k - x^{k-1}) = F(x^k) - F(x^{k-1})$$

$$\text{用迭代方法 } A^k = A^{k-1} + \Delta A^{k-1} \text{ 计算 } A^k$$

优化问题 $\min_x f(x)$

$\nabla f(x)$ 相当 $F(x)$

$\nabla^2 f(x)$ 相当 $F'(x)$, $\nabla^2 f$ 不一定正定, 构造正定阵 G 代替 $\nabla^2 f$

2000-11-11

14



无约束优化(搜索方向的选择) 3 拟Newton方法

设在第 k 步, G^k 已得到, $H^k=(G^k)^{-1}$,可计算

$$x^{k+1} = x^k - H^k \nabla f(x^k)$$

$$\text{记 } \Delta x^k = x^{k+1} - x^k, \Delta f^k = \nabla f(x^{k+1}) - \nabla f(x^k)$$

按照拟牛顿条件:

$$G^{k+1} \Delta x^k = \Delta f^k \text{ 或 } \Delta x^k = H^{k+1} \Delta f^k$$

构造迭代公式 $G^{k+1} = G^k + \Delta G^k$ 或 $H^{k+1} = H^k + \Delta H^k$

$$\text{于是有 } x^{k+2} = x^{k+1} - H^{k+1} \nabla f(x^{k+1})$$

2000-11-11

15



无约束优化(搜索方向的选择) 3 拟Newton方法

3.1 Davidon-Fletcher-Powell(DFP)公式

$$\Delta H^k = \frac{\Delta x^k (\Delta x^k)^T}{(\Delta x^k)^T \Delta f^k} - \frac{H^k \Delta f^k (\Delta f^k)^T H^k}{(\Delta f^k)^T H^k \Delta f^k}$$

$$\Delta G^k = \left(1 + \frac{(\Delta x^k)^T G^k \Delta x^k}{(\Delta x^k)^T \Delta f^k}\right) \frac{\Delta f^k (\Delta f^k)^T}{(\Delta x^k)^T \Delta f^k} - \frac{\Delta f^k (\Delta x^k)^T G^k + G^k \Delta x^k (\Delta f^k)^T}{(\Delta x^k)^T \Delta f^k}$$

特点

若迭代点处梯度非零, 则矩阵 H^k 对称正定, 并且具有二次终止性。

2000-11-11

16



无约束优化(搜索方向的选择) 3 拟Newton方法

3.2 Broyden-Fletcher-Goldfarb-Shanno(BFGS)公式

$$\Delta G^k = \frac{\Delta f^k (\Delta f^k)^T}{(\Delta f^k)^T \Delta x^k} - \frac{G^k \Delta x^k (\Delta x^k)^T G^k}{(\Delta x^k)^T G^k \Delta x^k}$$

$$\Delta H^k = \left(1 + \frac{(\Delta f^k)^T H^k \Delta f^k}{(\Delta x^k)^T \Delta f^k}\right) \frac{\Delta x^k (\Delta x^k)^T}{(\Delta x^k)^T \Delta f^k} - \frac{\Delta x^k (\Delta f^k)^T H^k + H^k \Delta f^k (\Delta x^k)^T}{(\Delta x^k)^T \Delta f^k}$$

特点 若 $(\Delta f^k)^T \Delta x_k > 0$, 则 H^k 对称正定, 且迭代2阶收敛

• **DFP与BFGS** 互为对偶: $\Delta x^k, \Delta f^k$ 互换, $\Delta G^k, \Delta H^k$ 互换

2000-11-11

17



无约束优化的基本方法(搜索步长的确定)

4 线性搜索确定步长方法

问题 给定 x^k 和方向 d^k , 确定步长 α^k , 使得

$$\min_{\alpha} f(x^k + \alpha d^k) \sim \text{一维优化问题}$$

$$\left. \frac{df}{d\alpha} \right|_{\alpha^k} = 0 \quad \Rightarrow \quad (d^k)^T \nabla f(x^k + \alpha^k d^k) = 0$$

**优化
算法**

黄金分割(0.618)法、Fibonacci法、Newton切线法、割线法、2次或3次插值法等

2000-11-11

18



无约束优化的基本方法

5 非线性最小二乘拟合方法

问题

给定 (t_i, y_i) , $i=1, \dots, n$, 拟合一个函数 $y=f(t, x)$,
其中 x 为待定的参数向量, f 对 x 非线性。

记误差 $r_i(x) = y_i - f(t_i, x)$ $r(x) = (r_1(x), \dots, r_n(x))^T$

优化模型

$$\min_x R(x) = r^T(x)r(x)$$

根据目标函数是 $r(x)$ 的二次函数的特点
构造简单算法

2000-11-11

19

无约束优化 (非线性最小二乘拟合)

$$R(x) = r^T(x)r(x)$$

记 $r(x)$ 的雅各比阵为 $J(x) = (\partial r_i / \partial x_j)_{n \times m}$

$$\nabla R = 2J(x)^T r(x) \quad \nabla^2 R = 2J(x)^T J(x) + 2S$$

$$S = \sum_{i=1}^n r_i(x) \nabla^2 r_i(x) \quad \nabla^2 r_i(x) = (\partial^2 r_i / \partial x_k \partial x_l)_{m \times m}$$

讨论

- 牛顿法要计算 **Hessian** 矩阵, 其中 **S** 计算量大。
- 若 f 对 x 线性, 则化为线性最小二乘拟合, 此时 **S=0**

特定算法考虑如何忽略或近似矩阵 **S**。

2000-11-11

20



无约束优化 (非线性最小二乘拟合)

5.1 Gauss-Newton算法: 忽略矩阵S

$$\nabla R = 2J(x)^T r(x) \quad \nabla^2 R = 2J(x)^T J(x)$$

牛顿方程 $\nabla^2 f(x^k)d = -\nabla f(x^k)$

f 用 R 代替, 下降方向 d^k 满足

$$J(x^k)^T J(x^k)d^k = -J(x^k)r(x^k)$$

G-N算法

收敛性依赖 f 对 x 的线性程度,
及偏差 r 的大小

2000-11-11

21



无约束优化 (非线性最小二乘拟合)

5.2 Levenberg-Marquardt算法: G-N算法修正

$$J(x^k)^T J(x^k)d^k = -J(x^k)r(x^k)$$



防止 $J^T J$ 出现病态

$$(J(x^k)^T J(x^k) + \alpha^k I)d^k = -J(x^k)r(x^k)$$


其中 $\alpha^k > 0$ 为修正参数.

L-M算法

d^k 位于牛顿方向(α^k 很小)和负梯度
方向(α^k 很大)之间

2000-11-11

22



优化工具箱 (matlab\toolbox\optim)

无约束优化

模型: $\underset{x}{\text{Min}} f(x), x \in R^n$


1) 基本程序:

输入: 的 文件名, 0 ~初始点,

输出: ~最优解

例 求解 $\min \frac{x^2}{a} + \frac{y^2}{b}, \quad a = b = 2$

examp071.m



2000-11-11

23

无约束优化

模型: $\underset{x}{\text{Min}} f(x), x \in R^n$

2) 提高精度, 观察中间结果, 给出迭代次数和最优值

输入: (缺省值) 无中间结果输出

中间结果输出

控制参数 设置最优解 的精度

设置最优值 的精度

输出: 最优值

迭代次数

例 $\min \frac{x_1^2}{a} + \frac{x_2^2}{b}, \quad a = 10, b = 1$

examp072.m

2

24

无约束优化

模型: $\underset{x}{\text{Min}} f(x), x \in R^n$

3) 算法选择:

输入:

(缺省值)

公式

公式

最速下降法

(缺省值) ~混合2,3次多项式插值
3次多项式插值

搜索方向

搜索步长

2000-11-1125

无约束优化

模型: $\underset{x}{\text{Min}} f(x), x \in R^n$

例3. $\min f(x, y) = 100(y - x^2)^2 + (1 - x)^2$

精确解: $x=y=1, f(x,y)=0$

计算结果

examp073.m

方向	步长	最优解 x	最优值 f	n
BFGS	2,3次	(9.9997e-001 9.9994e-001)	1.0944e-009	14
DFP	2,3次	(9.9997e-001 9.9994e-001)	2.1173e-009	1000
GRAD	2,3次	(-6.4113e-001 4.2250e-001)	2.7064e+000	1000
BFGS	3次	(1.0000e+000 9.9999e-001)	5.9567e-010	226
DFP	3次	(5.9547e-001 3.4591e-001)	1.7117e-001	220

2000-11-1126



无约束优化

模型: $\min_x f(x), x \in R^n$

4) 采用分析梯度:

$\nabla f(x)$ 的文件名

例4. $\min f(x, y) = 100(y - x^2)^2 + (1 - x)^2$

算出 $\nabla f = \begin{bmatrix} -400x(y - x^2) - 2(1 - x) \\ 200(y - x^2) \end{bmatrix}$

exam074.m

5) 其他: 用 输入最大迭代次数,
(缺省值 表示 为变量个数)。

2000-11-11

27

计算结果

方向	步长	最优解 x	最优值 f	n
BFGS	2,3次	(1.0000e+000 1.0000e+000)	6.3209e-011	54
DFP	2,3次	(3.7903e-001 1.3278e-001)	3.9744e-001	72
BFGS	3次	(1.0000e+000 1.0000e+000)	8.0378e-015	26
DFP	3次	(1.0001e+000 1.0003e+000)	2.2499e-008	25



与不用分析梯度的结果比较

方向	步长	最优解 x	最优值 f	n
BFGS	2,3次	(9.9997e-001 9.9994e-001)	1.0944e-009	14
DFP	2,3次	(9.9997e-001 9.9994e-001)	2.1173e-009	1000
GRAD	2,3次	(-6.4113e-001 4.2250e-001)	2.7064e+000	1000
BFGS	3次	(1.0000e+000 9.9999e-001)	5.9567e-010	226
DFP	3次	(5.9547e-001 3.4591e-001)	1.7117e-001	220

2000-11-11

28

$f(x, y) = 100(y - x^2)^2 + (1 - x)^2$ 的图形



2000-11-11

29

无约束优化 几个值得注意的问题

梯度函数：利用分析梯度可能改进算法的性能

算法选择：**foptions(6)=0**（缺省值）~ **BFGS**公式，
foptions(7)=0（缺省值）~混合2，3次插值，一般较好。

高度非线性、不连续时可用程序 **fmins**

精度控制：用**foptions(2:3)**控制，对迭代次数有重大影响，应适当选择。

改变初始值 由一个初值出发通常得到局部最优解，
如果函数存在多个局部最优，只有改变初值，对局部最优进行比较，才有可能得到全局最优解。

注：**fminu**将被**fminunc**取代；**fmins**将被**fminsearch**取代；
foptions将被**optimset**，**optimget**取代（用法有变化）



优化工具箱 (matlab\toolbox\optim)

非线性最小二乘方法

$$\min_x R(x) = r^T(x)r(x)$$

$$r_i(x) = y_i - f(t_i, x)$$

$$r(x) = (r_1(x), \dots, r_n(x))^T$$

输入的用法与 `lsqnonlin` 相同，但注意：
的文件名，`∇r(x)` 的文件名

输出 = (误差向量)，`T`

注：leastsq 将被 lsqnonlin 取代（用法有变化）；

数据拟合也可用 curvefit（将被 lsqcurvefit 取代）



优化实例

实例1 产销量安排

$$p_i = b_i - a_{i1}x_1 - a_{i2}x_2, \quad b_i, a_{i1}, a_{i2} > 0, \quad i = 1, 2,$$

原问题

$$q_i = r_i e^{-\lambda_i x_i} + c_i, \quad r_i, \lambda_i, c_i > 0, \quad i = 1, 2,$$

$$\max_{x_1, x_2} z(x_1, x_2) = (p_1 - q_1)x_1 + (p_2 - q_2)x_2$$

已知
数据

$$\begin{pmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \end{pmatrix} = \begin{pmatrix} 1 & 0.1 \\ 0.2 & 2 \end{pmatrix} \quad b = \begin{pmatrix} 100 \\ 280 \end{pmatrix}$$

$$r^T = (30 \quad 100), \quad \lambda^T = (0.015 \quad 0.02), \quad c^T = (20 \quad 30)$$

$$\min f(x) = -(b_1 - a_{11}x_1 - a_{12}x_2 - r_1 e^{-\lambda_1 x_1} - c_1)x_1 \\ - (b_2 - a_{21}x_1 - a_{22}x_2 - r_2 e^{-\lambda_2 x_2} - c_2)x_2$$

2000-11-11

32



优化实例

实例1 产销量安排

初始点的
选择

忽略成本及价
格中的 a_{12}, a_{21}

$$\begin{pmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \end{pmatrix} = \begin{pmatrix} 1 & 0.1 \\ 0.2 & 2 \end{pmatrix}$$

问题简化为 $\min f(x) = -(b_1 - a_{11}x_1)x_1 - (b_2 - a_{22}x_2)x_2$

其解为 $x_1 = b_1 / 2a_{11} = 50, x_2 = b_2 / 2a_{22} = 70$

作为原问题的初始点

命令和最优解

`x=fminu('f(x)', x0)`

shili071.m

$x = 23.9025 \quad 62.4977 \quad y = 6.4135e+003$

即甲产量为 23.9025, 乙产量为 62.4977, 最大利润为 6413.5

2000-11-11

33



优化实例

实例2 药物的吸收与排除

原问题

$$c(t) = \frac{d}{V} \frac{k_1}{k_1 - k} (e^{-kt} - e^{-k_1 t})$$

测得一组数据
 $(t_i, c_i), i=1, \dots, n$

用非线性最小二乘拟合求参数 k, k_1, V , 使误差 R 最小

$$R(k, k_1, V) = \sum_{i=1}^n [c(t_i) - c_i]^2 = \sum_{i=1}^n \left[\frac{d}{V} \frac{k_1}{k_1 - k} (e^{-kt_i} - e^{-k_1 t_i}) - c_i \right]^2$$


拟合结果为 $(k_1, k, d/V) = (3.6212, 0.2803, 46.8275)$

根据 d/V 和 d 可计算 V

shili072.m

2000-11-11

34



无约束优化实验内容

实验目的

1. 掌握 Matlab 优化工具包的基本用法，对不同算法进行初步分析、比较。
2. 练习实际问题的非线性最小二乘拟合。

内容 2; 6(参看182页及198页内容)