

计算方法及 MATLAB 实现

郑勋烨 编著

主审： 高世臣 褚宝增 王祖朝 王翠香

副审： 李少琪 李明霞 赵琳琳 赵俊芳

国防工业出版社

第七章 矩阵特征值计算

7.1 幂法和反幂法 (Power Method)

7.1.1 幂法

幂法 (Power Method) 和反幂法 (Inverse Power Method) 是利用迭代序列计算矩阵 A 和非奇异矩阵的逆矩阵 A^{-1} 的主特征值和主特征向量的方法. 它们本质上都是属于 **迭代方法**. 与之相对的则是变换方法, 包括著名的 Householder 方法和 QR 方法等等.

【定义 1. 主特征值和主特征向量】

矩阵 $A = (a_{ij})_{n \times n} \in R^{n \times n}$ 的所有特征值依照模从大到小的次序排列为

$$|\lambda_1| > |\lambda_2| \geq \cdots \geq |\lambda_n| \geq 0$$

则矩阵 A 的 **主特征值** 正是矩阵 A 的模极大的特征值 λ_1 . 它的模 严格大于 序列后面的所有特征值的模. 矩阵 A 的 **主特征值** λ_1 对应的特征向量 v_1 称为矩阵 A 的 **主特征向量**.

倘若矩阵 A 的模极大的特征值 λ_1 是 r 重根，所有特征值依照模从大到小的次序排列为

$$|\lambda_1| = |\lambda_2| = \cdots = |\lambda_r| > |\lambda_{r+1}| \geq \cdots \geq |\lambda_n| \geq 0$$

则主特征值 λ_1 对应的 r 个线性无关特征向量 v_1, v_2, \cdots, v_r 称为矩阵 A 的主特征向量.

【 幂法 (Power Method) 的引入 】

由于矩阵 A 的所有特征值对应的线性无关特征向量系

$$v_1, v_2, \cdots, v_n$$

可以构成向量空间 R^n (或 C^n) 的标准正交基. 对于任意非零实向量 $x_0 \neq 0 \in R^n$ (或非零复向量 $x \neq 0 \in C^n$), 我们有在这个基下的线性组合表示

$$x_0 = c_1 v_1 + c_2 v_2 + \cdots + c_n v_n, \quad c_1^2 + c_2^2 + \cdots + c_n^2 > 0$$

此时 以矩阵 A 为迭代映射 构造迭代序列

$$\begin{aligned}x_1 = Ax_0 &= c_1Av_1 + c_2Av_2 + \cdots + c_nAv_n \\&= c_1\lambda_1v_1 + c_2\lambda_2v_2 + \cdots + c_n\lambda_nv_n\end{aligned}$$

$$x_2 = Ax_1 = A^2x_0 = c_1\lambda_1^2v_1 + c_2\lambda_2^2v_2 + \cdots + c_n\lambda_n^2v_n$$

.....

$$x_k = Ax_{k-1} = A^kx_0 = c_1\lambda_1^kv_1 + c_2\lambda_2^kv_2 + \cdots + c_n\lambda_n^kv_n$$

$$\begin{aligned}x_{k+1} = Ax_k &= A^{k+1}x_0 \\&= c_1\lambda_1^{k+1}v_1 + c_2\lambda_2^{k+1}v_2 + \cdots + c_n\lambda_n^{k+1}v_n\end{aligned}$$

.....

对于一般的第 k 步迭代表达式, 我们提取出公因子 λ_1^k , 则有

$$\begin{aligned}x_k &= Ax_{k-1} = A^k x_0 = c_1 \lambda_1^k v_1 + c_2 \lambda_2^k v_2 + \cdots + c_n \lambda_n^k v_n \\&= \lambda_1^k \left[c_1 v_1 + c_2 \left(\frac{\lambda_2}{\lambda_1} \right)^k v_2 + \cdots + c_n \left(\frac{\lambda_n}{\lambda_1} \right)^k v_n \right] \\&= \lambda_1^k \left[c_1 v_1 + \sum_{j=2}^n c_j \left(\frac{\lambda_j}{\lambda_1} \right)^k v_j \right] \\&= \lambda_1^k [c_1 v_1 + \varepsilon_k]\end{aligned}$$

其中 $\varepsilon_k = \sum_{j=2}^n c_j \left(\frac{\lambda_j}{\lambda_1}\right)^k v_j$. 由于 $|\lambda_1| > |\lambda_2| \geq \cdots \geq |\lambda_n|$, 故而 $\left|\frac{\lambda_j}{\lambda_1}\right| < 1$. 于是

$$\varepsilon_k = \sum_{j=2}^n c_j \left(\frac{\lambda_j}{\lambda_1}\right)^k v_j \longrightarrow 0, \quad k \longrightarrow +\infty$$

从而

$$\lim_{k \longrightarrow +\infty} \frac{x_k}{\lambda_1^k} = \lim_{k \longrightarrow +\infty} [c_1 v_1 + \varepsilon_k] = c_1 v_1$$

换言之，当 $k \longrightarrow +\infty$ 充分大时，向量

$$x_k \approx c_1 \lambda_1^k v_1$$

亦即迭代向量 x_k 可以作为矩阵 A 的主特征值 λ_1 对应的主特征向量 v_1 的近似向量.

对于 A 的主特征值 λ_1 的计算, 我们如下进行. 由

$$\begin{cases} x_k &= \lambda_1^k [c_1 v_1 + \varepsilon_k] = (x_k^{(1)}, x_k^{(2)}, \dots, x_k^{(n)}) \\ x_{k+1} &= \lambda_1^{k+1} [c_1 v_1 + \varepsilon_{k+1}] = (x_{k+1}^{(1)}, x_{k+1}^{(2)}, \dots, x_{k+1}^{(n)}) \end{cases}$$

对于向量的第 $i, 1 \leq i \leq n$ 个分量比较, 即有

$$x_k^{(i)} = \lambda_1^k [c_1 v_1^{(i)} + \varepsilon_k^{(i)}] \quad (1)$$

$$x_{k+1}^{(i)} = \lambda_1^{k+1} [c_1 v_1^{(i)} + \varepsilon_{k+1}^{(i)}] \quad (2)$$

用 (2) 式除以 (1) 式得

$$\frac{x_{k+1}^{(i)}}{x_k^{(i)}} = \lambda_1 \frac{c_1 v_1^{(i)} + \varepsilon_{k+1}^{(i)}}{c_1 v_1^{(i)} + \varepsilon_k^{(i)}}$$

令 $k \longrightarrow +\infty$ 充分大取极限时, 有

$$\lim_{k \longrightarrow +\infty} \frac{x_{k+1}^{(i)}}{x_k^{(i)}} = \lambda_1 \lim_{k \longrightarrow +\infty} \frac{c_1 v_1^{(i)} + \varepsilon_{k+1}^{(i)}}{c_1 v_1^{(i)} + \varepsilon_k^{(i)}} = \lambda_1$$

亦即迭代向量 x_{k+1} 的第 i 个分量与迭代向量 x_k 的第 i 个分量的比值可以作为矩阵 A 的主特征值 λ_1 的近似值.

对于矩阵 A 的模极大的主特征值 λ_1 是 r 重根的情况可类似证明。我们有如下结论：

【定理 1. 幂法 (Power Method) 收敛定理】

矩阵 $A = (a_{ij})_{n \times n} \in R^{n \times n}$ 的所有特征值依照模从大到小的次序排列为

$$|\lambda_1| > |\lambda_2| \geq \cdots \geq |\lambda_n| \geq 0$$

则矩阵 A 的 **主特征值** 正是矩阵 A 的模极大的特征值 λ_1 . 对应的特征向量称为矩阵 A 的 **主特征向量**. 则矩阵 A 的所有特征值对应的线性无关特征向量系 v_1, v_2, \cdots, v_n , 可以构成向量空间 R^n (或 C^n) 的基向量系.

对于任意非零实向量 $x_0 \neq 0 \in R^n$ (或非零复向量 $x \neq 0 \in C^n$) , 我们有在这个基下的线性组合表示

$$x_0 = c_1 v_1 + c_2 v_2 + \cdots + c_n v_n, \quad c_1^2 + c_2^2 + \cdots + c_n^2 > 0$$

此时以矩阵 A 为迭代映射构造迭代序列

$$x_k = Ax_{k-1} = A^k x_0 = c_1 \lambda_1^k v_1 + c_2 \lambda_2^k v_2 + \cdots + c_n \lambda_n^k v_n$$

当 $k \longrightarrow +\infty$ 充分大时,

$$\lim_{k \longrightarrow +\infty} \frac{x_k}{\lambda_1^k} = c_1 v_1$$

换言之，迭代向量

$$x_k \approx c_1 \lambda_1^k v_1$$

亦即迭代向量 x_k 可以作为矩阵 A 的主特征值 λ_1 对应的 **主特征向量** v_1 的近似向量.

而

$$\lambda_1 = \lim_{k \rightarrow +\infty} \frac{x_{k+1}^{(i)}}{x_k^{(i)}}$$

亦即迭代向量 x_{k+1} 的第 i 个分量与迭代向量 x_k 的第 i 个分量的比值可以作为矩阵 A 的主特征值 λ_1 的近似值.

倘若矩阵 A 的模极大的主特征值 λ_1 是 r 重根, 所有特征值依照模从大到小的次序排列为

$$|\lambda_1| = |\lambda_2| = \cdots = |\lambda_r| > |\lambda_{r+1}| \geq \cdots \geq |\lambda_n| \geq 0$$

对应的 r 个线性无关特征向量 v_1, v_2, \cdots, v_r 为主特征向量. 此时以矩阵 A 为迭代映射构造迭代序列

$$x_k = Ax_{k-1} = A^k x_0 = \lambda_1^k \left[\sum_{j=1}^r c_j v_j + \sum_{j=r+1}^n c_j \left(\frac{\lambda_j}{\lambda_1} \right)^k v_j \right]$$

当 $k \longrightarrow +\infty$ 充分大时,

$$\lim_{k \longrightarrow +\infty} \frac{x_k}{\lambda_1^k} = \sum_{j=1}^r c_j v_j$$

换言之, 迭代向量

$$x_k \approx c_1 \lambda_1^k \sum_{j=1}^r c_j v_j$$

亦即迭代向量 x_k 可以作为矩阵 A 的主特征值 $\lambda_1 = \cdots = \lambda_r$ 对应的主特征向量 v_1, v_2, \cdots, v_r 的线性组合的近似向量.

而与主特征值 λ_1 是单根的情形类似有

$$\lambda_1 = \lim_{k \rightarrow +\infty} \frac{x_{k+1}^{(i)}}{x_k^{(i)}}$$

亦即迭代向量 x_{k+1} 的第 i 个分量与迭代向量 x_k 的第 i 个分量的比值可以作为矩阵 A 的主特征值 λ_1 的近似值.

【 幂法 (Power Method) 的标准化 】

我们引入 迭代向量 x_k 的第一个具有最大模的坐标分量 $x_k^{(i_0)}$ ，即此分量的模恰好等于向量 x_k 的 最大模范数 $|x_k^{(i_0)}| = \|x_k\|_\infty$ ，而它又是所有具有最大模的坐标分量中首先出现的 (后面可能还有具有最大模的坐标分量，比如向量 $(1, 1, \dots, 1)^T$). 换言之，标记 i_0 是 “最小的” 或 “头一号”.

我们并标记此分量为 $x_k^{(i_0)} = \max(x_k)$. 这是个约定俗成的记法. 即 $x_k^{(i_0)} = \max(x_k) := \pm \|x_k\|_\infty$,

$$|x_k^{(i_0)}| = |\max(x_k)| = \|x_k\|_\infty = \max(|x_k^{(1)}|, |x_k^{(2)}|, \dots, |x_k^{(n)}|)$$

令 标准化迭代向量

$$y_k := \frac{x_k}{\max(x_k)} = \frac{x_k}{x_k^{(i_0)}}$$

则向量 y_k 的 最大模范数 为 1:

$$\|y_k\|_\infty = \frac{\|x_k\|_\infty}{|\max(x_k)|} = \frac{\|x_k\|_\infty}{\|x_k\|_\infty} = 1$$

计算实践中使用幂法，是将 标准化迭代程序 在每一步里操作，就是“迭代 \longrightarrow 标准化 \longrightarrow 迭代 \longrightarrow 标准化 \longrightarrow 迭代 \cdots ”。我们获得的是如下 标准化幂法迭代程序 序列：

$$\left\{ \begin{array}{l} x_1 = Ax_0 = Ay_0 \\ y_1 = \frac{x_1}{\max(x_1)} = \frac{Ax_0}{\max(Ax_0)} \\ x_2 = Ay_1 = \frac{A^2x_0}{\max(Ax_0)} \\ y_2 = \frac{x_2}{\max(x_2)} = \frac{A^2x_0}{\max(A^2x_0)} \\ \dots\dots\dots \\ x_k = Ay_{k-1} = \frac{A^kx_0}{\max(A^{k-1}x_0)}, \\ y_k = \frac{x_k}{\max(x_k)} = \frac{A^kx_0}{\max(A^kx_0)} \\ \dots\dots\dots \end{array} \right.$$

【例 1. 标准化幂法迭代】

对如下矩阵 A ，给定初始非零向量 $x_0 = (1, 1, 1)^T$. 试求对应于特征值 $\lambda_1 = 4$ 的特征向量:

$$A = \begin{pmatrix} 4 & 0 & 0 \\ 0 & 3 & 1 \\ 0 & 1 & 3 \end{pmatrix}$$

分别用代数方法和数值方法求解并比较.

解

特征矩阵

$$\lambda I - A = \begin{pmatrix} \lambda - 4 & 0 & 0 \\ 0 & \lambda - 3 & -1 \\ 0 & -1 & \lambda - 3 \end{pmatrix}$$

特征方程 $|\lambda E - A| = (\lambda - 4)^2(\lambda - 2) = 0$. 故特征根:
 $\lambda_1 = \lambda_2 = 4$ 为重根, $\lambda_3 = 2$ 为单根.

求特征向量:

对重根 $\lambda_1 = \lambda_2 = 4$, 我们有

$$\lambda = 4, (\lambda E - A)\alpha = 0, \begin{pmatrix} 0 & 0 & 0 \\ 0 & 1 & -1 \\ 0 & -1 & 1 \end{pmatrix} \begin{pmatrix} a_1 \\ a_2 \\ a_3 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \\ 0 \end{pmatrix},$$

即 $a_2 - a_3 = 0$. 取 $a_1 = a_2 = a_3 = 1$, 得一个特征向量 $\alpha_1 = (1, 1, 1)^T$.

用幂法迭代求解.

给定初始非零向量 $x_0 = (1, 1, 1)^T$ (这里初始向量碰巧选择得好, 就是特征向量! 多数情况要尝试), 标准化幂法迭代程序 序列为

$x_1 = Ax_0 = Ay_0,$	$y_1 = \frac{x_1}{\max(x_1)} = \frac{Ax_0}{\max(Ax_0)}$
$x_2 = \frac{A^2x_0}{\max(Ax_0)},$	$y_2 = \frac{x_2}{\max(x_2)} = \frac{A^2x_0}{\max(A^2x_0)}$
.....
$x_k = \frac{A^kx_0}{\max(A^{k-1}x_0)},$	$y_k = \frac{x_k}{\max(x_k)} = \frac{A^kx_0}{\max(A^kx_0)}$
.....

迭代一步就是

$$\begin{aligned}x_1 = Ax_0 &= \begin{pmatrix} 4 & 0 & 0 \\ 0 & 3 & 1 \\ 0 & 1 & 3 \end{pmatrix} \begin{pmatrix} 1 \\ 1 \\ 1 \end{pmatrix} = \begin{pmatrix} 4 \\ 4 \\ 4 \end{pmatrix} \\ y_1 = \frac{x_1}{\max(x_1)} &= \frac{(4, 4, 4)^T}{\max(4, 4, 4)^T} = \frac{(4, 4, 4)^T}{4} = (1, 1, 1)^T\end{aligned}$$

倘若任意选择初始非零向量 $x_0 = (2, 1, 0)^T$, 标准化幂法迭代程序 序列迭代一步就是

$$\begin{aligned} x_1 = Ax_0 &= \begin{pmatrix} 4 & 0 & 0 \\ 0 & 3 & 1 \\ 0 & 1 & 3 \end{pmatrix} \begin{pmatrix} 2 \\ 1 \\ 0 \end{pmatrix} = \begin{pmatrix} 8 \\ 3 \\ 1 \end{pmatrix} \\ y_1 = \frac{x_1}{\max(x_1)} &= \frac{(8, 3, 1)^T}{\max(8, 3, 1)^T} = \frac{(8, 3, 1)^T}{8} = (1, \frac{3}{8}, \frac{1}{8})^T \end{aligned}$$

标准化幂法迭代程序 序列再迭代一步就是

$$\begin{aligned}x_2 = Ay_1 &= \begin{pmatrix} 4 & 0 & 0 \\ 0 & 3 & 1 \\ 0 & 1 & 3 \end{pmatrix} \begin{pmatrix} 1 \\ \frac{3}{8} \\ \frac{1}{8} \end{pmatrix} = \begin{pmatrix} 4 \\ \frac{10}{8} \\ \frac{6}{8} \end{pmatrix} \\ y_2 = \frac{x_2}{\max(x_2)} &= \frac{(4, \frac{10}{8}, \frac{6}{8})^T}{\max(4, \frac{10}{8}, \frac{6}{8})^T} = \frac{(4, \frac{10}{8}, \frac{6}{8})^T}{4} = (1, \frac{10}{32}, \frac{6}{32})^T\end{aligned}$$

而改进迭代向量 x_2 的第 1 个具有最大模的分量可以作为矩阵 A 的主特征值 λ_1 的近似值:

$$\lambda_1 \approx \max(x_2) = 4$$

事实上它已经达到了真值！

7.1.2 幂法的加速 (Acceleration of Power Method)

我们看到, 幂法的原始迭代为

$$x_k = Ax_{k-1} = A^k x_0 = \lambda_1^k [c_1 v_1 + \varepsilon_k]$$

其中 $\varepsilon_k = \sum_{j=2}^n c_j \left(\frac{\lambda_j}{\lambda_1}\right)^k v_j$. 由于 $|\lambda_1| > |\lambda_2| \geq \cdots \geq |\lambda_n|$, 故而 $\left|\frac{\lambda_j}{\lambda_1}\right| < 1$.

于是余项向量

$$\varepsilon_k = \sum_{j=2}^n c_j \left(\frac{\lambda_j}{\lambda_1} \right)^k v_j \longrightarrow 0, \quad k \longrightarrow +\infty$$

显然，余项向量趋向于 0 的速度越快，幂法的收敛速度越快。从而幂法 (Power Method) 的收敛速度取决于比值 (次大特征值和最大特征值模的比值)

$$r = \left| \frac{\lambda_2}{\lambda_1} \right| < 1$$

我们希望比值越小越好。当 $r \ll 1$ 时，收敛速度比较快。但若当 $r \approx 1$ 时，收敛速度可能很慢。此时我们需要对迭代进行加速。

【 加速方法 1. 原点位移加速 (Shift Acceleration of Power Method) 】

矩阵 $A = (a_{ij})_{n \times n}$ 的所有特征值依照模从大到小的次序排列为

$$|\lambda_1| > |\lambda_2| \geq \cdots \geq |\lambda_n| \geq 0$$

矩阵 A 的主特征值是模极大的特征值 λ_1 . 对应的特征向量 v_1 为主特征向量.

引入参数 p , 辅助矩阵 $B = A - pI$ 的所有特征值为

$$\lambda_1 - p, \lambda_2 - p, \cdots, \lambda_n - p$$

适当选择参数 p , 使得辅助矩阵 $B = A - pI$ 的主特征值为 $\lambda_1 - p$, 且

$$\frac{|\lambda_2 - p|}{|\lambda_1 - p|} < r = \left| \frac{\lambda_2}{\lambda_1} \right| < 1$$

【命题 1】

矩阵 $A = (a_{ij})_{n \times n}$ 的所有特征值全是实数（比如 Hermite 矩阵或实对称矩阵特征值就全是实数），依照从大到小的次序排列为

$$\lambda_1 > \lambda_2 \geq \cdots \geq \lambda_{n-1} > \lambda_n$$

当选择参数 $\lambda_n < p^* < \lambda_2$ 为中点

$$p^* = \frac{\lambda_2 + \lambda_n}{2}$$

时辅助矩阵 $B = A - pI$ 的收敛速度的比值达到最小值.

【证明略】

【释例. 原点位移加速幂法】

某四阶矩阵 A 具有特征根:

$$\lambda_1 = 14, \lambda_2 = 13, \lambda_3 = 12, \lambda_4 = 11$$

试求收敛速度比 $r = \left| \frac{\lambda_2}{\lambda_1} \right|$.

适当选择参数 p , 构造原点位移辅助矩阵 $B = A - pI$ 再求收敛速度比

$$r = \max\left(\frac{|\lambda_2 - p|}{|\lambda_1 - p|}, \frac{|\lambda_n - p|}{|\lambda_1 - p|}\right)$$

并比较位移前后的收敛速度.

解

四阶矩阵 A 具有特征根:

$$\lambda_1 = 14, \lambda_2 = 13, \lambda_3 = 12, \lambda_4 = 11$$

于是收敛速度比

$$r = \left| \frac{\lambda_2}{\lambda_1} \right| = \frac{\lambda_2}{\lambda_1} = \frac{13}{14} \approx 0.92857$$

适当选择参数

$$p = \frac{\lambda_2 + \lambda_n}{2} = \frac{13 + 11}{2} = 12$$

构造原点位移辅助矩阵 $B = A - pI = A - 12I$, 则 收敛速度比

$$r = \max\left(\frac{|\lambda_2 - p|}{|\lambda_1 - p|}, \frac{|\lambda_n - p|}{|\lambda_1 - p|}\right) = \frac{|\lambda_2 - p|}{|\lambda_1 - p|} = \frac{13 - 12}{14 - 12} \approx 0.5$$

位移后的收敛速度大大加快.

【例 1. 原点位移加速幂法】

令 初始迭代向量 $x_0 = y_0 = (1, 1, 1)^T$. 适当选择参数 $p = -0.5$, 构造原点位移辅助矩阵 $B = A - pI$, 求矩阵

$$A = \begin{pmatrix} 1 & 2 & 3 \\ 2 & 3 & 4 \\ 3 & 4 & 5 \end{pmatrix}$$

的主特征值和主特征向量.

解 用原点位移加速幂法迭代求解.

取参数 $p = -0.5$, 构造 原点位移矩阵

$$B = (A - pI) = \begin{pmatrix} 1 + 0.5 & 2 & 3 \\ 2 & 3 + 0.5 & 4 \\ 3 & 4 & 5 + 0.5 \end{pmatrix}$$
$$= \begin{pmatrix} 1.5 & 2 & 3 \\ 2 & 3.5 & 4 \\ 3 & 4 & 5.5 \end{pmatrix}$$

以 原点位移矩阵 $B = (A - pI)$ 为迭代映射构造幂法迭代序列

$$\left\{ \begin{array}{l} x_0 = y_0 = (1, 1, 1)^T \\ x_k = By_{k-1} = (A - pI)y_{k-1} \\ \mu_k = \max(x_k) \\ y_k = \frac{x_k}{\mu_k} = \frac{x_k}{\max(x_k)} \end{array} \right.$$

迭代一步就是

$$\begin{pmatrix} x_1^{(1)} \\ x_1^{(2)} \\ x_1^{(3)} \end{pmatrix} = \begin{pmatrix} 1.5 & 2 & 3 \\ 2 & 3.5 & 4 \\ 3 & 4 & 5.5 \end{pmatrix} \begin{pmatrix} 1 \\ 1 \\ 1 \end{pmatrix} = \begin{pmatrix} 6.5 \\ 9.5 \\ 12.5 \end{pmatrix}$$

标准化得

$$y_1 = \frac{x_1}{\max(x_1)} = \frac{(6.5, 9.5, 12.5)^T}{12.5} = (0.52, 0.76, 1)^T$$

再迭代一步就是

$$\begin{pmatrix} x_2^{(1)} \\ x_2^{(2)} \\ x_2^{(3)} \end{pmatrix} = \begin{pmatrix} 1.5 & 2 & 3 \\ 2 & 3.5 & 4 \\ 3 & 4 & 5.5 \end{pmatrix} \begin{pmatrix} 0.52 \\ 0.76 \\ 1 \end{pmatrix} = \begin{pmatrix} 5.3 \\ 7.7 \\ 10.1 \end{pmatrix}$$

标准化得

$$y_2 = \frac{x_2}{\max(x_2)} = \frac{(5.3, 7.7, 10.1)^T}{10.1} = (0.52475, 0.76237624, 1)^T$$

迭代向量 $x_2 = (5.3, 7.7, 10.1)^T$ 的最大模分量接近于 位移矩阵 $B = (A - pI)$ 的精确的主特征值

$$\lambda_1 \approx \max(x_2) = 10.1$$

从而由于对应的 原始矩阵 A 的 主特征值 $\lambda_1(A) = \lambda_1 - p$,
故 $\lambda_1(A)$ 的近似值为

$$\lambda_1(A) \approx p + \max(x_2) = -0.5 + 10.1 = 9.6$$

并且对应的 主特征向量 为

$$y_2 = (0.52475, 0.76237624, 1)^T$$